

Database를 활용한 헬스케어 데이터 분석

2일차: SQL 기초 및 고급 문법

| 목차

- 1일차 복습
- SQL
- JOIN
- **GROUP BY / HAVING / LIMIT / Aggregation**

1일차 복습

Database를 배우는 이유

EDA 한계

CSV는 작을 때만 가능

데이터가 늘면 느리고 메모리 부족

여러 파일을 결합할 때 불편 (merge 반복)

데이터 업데이트가 많을 때 유지보수 어려움

여러 사람이 동시에 작업 불가

Database란

데이터를 정리된 구조로 안전하게 저장하는 시스템

- 여러 표(table)로 나누어 저장
- 안전하게 보관
- 빠르게 검색
- 많은 사람들이 동시에 사용 가능


데이터베이스 기본 용어 정리

- Database: 데이터를 모아 저장하는 공간
- DBMS: Database를 관리하는 시스템
- RDBMS: 관계형 DBMS
- Instance: 특정 시점에 저장된 데이터 상태
- Domain: Column이 가질 수 있는 값의 범위/유형

데이터베이스 기본 용어 정리

- Table: 실제 데이터가 저장된 표 형태
- Row: 데이터 한 건
- Column: 하나의 속성
- Schema: 테이블 구조 (Column, 타입, 제약조건)

Related DataBase Management System




관계형 데이터베이스

- 정형 데이터 + 관계형 구조
- MySQL, PostgreSQL, Oracle
- 모든 값은 원자값 (Atomic): 하나의 셀에는 하나의 값만
- 헬스케어 핵심 시스템 기반

Entity-Relationship Diagram

데이터가 어떤 엔티티로 구성되고 어떻게 연결되는지 시각적으로 표현하는 도구

- 시스템 데이터 구조 파악
- PK/FK 관계 정의
- 테이블 설계의 근거



SQL 기초

Structured Query Language

- 관계형 데이터베이스에서 데이터를 저장, 검색, 수정 및 관리하기 위해 사용되는 표준화된 프로그래밍 언어
- 대량의 데이터를 빠르고 효율적으로 처리할 수 있는 최적화된 성능 제공

오늘 배우는 SQL 핵심 3개

- SELECT
- WHERE
- ORDER BY

접속!! <https://www.sql-practice.com/>

SELECT 기본 구조

```
SELECT column1, column2, ...  
FROM table_name;
```

- 테이블에서 특정 column을 선택하여 조회
- **SELECT *:** 전체 컬럼 조회

```
1 SELECT * FROM patients;
```

patient_id	first_name	last_name	gender	birth_date	city	province_id	allergies	height	weight
1	Donald	Waterfield	M	1963-02-12	Barrie	ON	NULL	156	65
2	Mickey	Baasha	M	1981-05-28	Dundas	ON	Sulfa	185	76
3	Jiji	Sharma	M	1957-09-05	Hamilton	ON	Penicillin	194	106
4	Blair	Diaz	M	1967-01-07	Hamilton	ON	NULL	191	104
5	Charles	Wolfe	M	2017-11-19	Orillia	ON	Penicillin	47	10

WHERE 조건문 기본

```
SELECT column1, column2, ...  
FROM table_name  
WHERE 조건;
```

- 조건에 맞는 행(row)만 가져오기
- =, <, <=, BETWEEN, IN, LIKE, IS NULL, IS NOT NULL

WHERE 조건문 기본

```
SELECT column1, column2, ...  
FROM table_name  
WHERE 조건;
```

```
1 SELECT * FROM patients  
2 WHERE height BETWEEN 140 AND 170;
```

patient_id	first_name	last_name	gender	birth_date	city	province_id	allergies	height	weight
1	Donald	Waterfield	M	1963-02-12	Barrie	ON	NULL	156	65
10	Cedric	Coltrane	M	1961-11-10	Toronto	ON	NULL	157	61
11	Hank	Spencer	M	1969-08-10	Peterborough	ON	NULL	158	74
12	Sara	di Marco	F	1949-04-29	Hamilton	ON	NULL	145	46
13	Daphne	Seabright	F	1954-11-18	Ancaster	ON	Codeine	146	77
16	Woody	Bashir	M	1951-11-15	Barrie	ON	Penicillin	153	59

WHERE 조건문 기본

```
SELECT column1, column2, ...  
FROM table_name  
WHERE 조건;
```

```
1 SELECT * FROM patients  
2 WHERE allergies IS NOT NULL;
```

patient_id	first_name	last_name	gender	birth_date	city	province_id	allergies	height	weight
2	Mickey	Baasha	M	1981-05-28	Dundas	ON	Sulfa	185	76
3	Jiji	Sharma	M	1957-09-05	Hamilton	ON	Penicillin	194	106
5	Charles	Wolfe	M	2017-11-19	Orillia	ON	Penicillin	47	10
6	Sue	Falcon	F	2017-09-30	Ajax	ON	Penicillin	43	5
9	Sister	Spitzer	F	1966-10-15	Toronto	ON	Penicillin	173	95

WHERE 조건문 기본

```
SELECT column1, column2, ...  
FROM table_name  
WHERE 조건;
```

```
1 SELECT * FROM patients  
2 WHERE first_name LIKE 'A%';  
3 -- WHERE first_name like '%0%';  
4 -- WHERE first_name like '%y';
```

patient_id	first_name	last_name	gender	birth_date	city	province_id	allergies	height	weight
15	Amy	Leela	F	1977-06-25	Hamilton	ON	NULL	172	72
21	Angel	Edwards	F	1975-08-22	Brantford	ON	NULL	176	106
35	Anthony	Maxwell	M	2011-02-11	Oakville	ON	NULL	92	37

WHERE 조건문 기본

```
SELECT column1, column2, ...  
FROM table_name  
WHERE 조건;
```

```
1 SELECT * FROM patients  
2 WHERE city IN ('Barrie', 'Oakville');
```

patient_id	first_name	last_name	gender	birth_date	city	province_id	allergies	height	weight
1	Donald	Waterfield	M	1963-02-12	Barrie	ON	NULL	156	65
16	Woody	Bashir	M	1951-11-15	Barrie	ON	Penicillin	153	59
19	John	West	M	1961-06-19	Oakville	ON	NULL	138	61
35	Anthony	Maxwell	M	2011-02-11	Oakville	ON	NULL	92	37
132	Haiku	Shaft	M	2006-02-19	Barrie	ON	NULL	155	55

WHERE 조건문 기본

```
SELECT column1, column2, ...  
FROM table_name  
WHERE 조건;
```

```
1 SELECT * FROM patients  
2 WHERE birth_date >= '2001-01-01';
```

patient_id	first_name	last_name	gender	birth_date	city	province_id	allergies	height	weight
5	Charles	Wolfe	M	2017-11-19	Orillia	ON	Penicillin	47	10
6	Sue	Falcon	F	2017-09-30	Ajax	ON	Penicillin	43	5
24	Nino	Andrews	M	2001-04-21	Hamilton	ON	Peanuts	186	85
30	Roderick	Payne	M	2015-03-22	Halifax	NS	NULL	58	17
32	Bertha	Crowley	F	2009-03-14	Delhi	ON	NULL	125	39

ORDER BY 기본

```
SELECT column1, column2, ...  
FROM table_name  
ORDER BY column ASC; 또는 DESC;
```

```
1 SELECT * FROM patients  
2 ORDER BY birth_date;
```

patient_id	first_name	last_name	gender	birth_date	city	province_id	allergies	height	weight
115	Briareos	Hayes	M	1918-12-12	Sarnia	ON	Morphine	189	138
2029	Fred	Petrie	M	1923-01-25	Hamilton	ON	NULL	141	82
72	Lily	Vargas	F	1923-05-02	Hamilton	ON	Codeine	195	102
3075	Marsellus	Falcone	M	1925-03-14	Smithville	ON	Codeine	202	124
1411	Claire	Parkinson	F	1925-07-15	Dunton	ON	NULL	186	103

WHERE + ORDER BY

SELECT column1, column2, ...

FROM table_name

WHERE 조건

ORDER BY column ASC; <- 항상 WHERE 뒤에 있어야 함

```
1 SELECT *
2 FROM patients
3 WHERE province_id == 'ON'
4 ORDER BY birth_date ASC;
```

patient_id	first_name	last_name	gender	birth_date	city	province_id	allergies	height	weight
115	Briareos	Hayes	M	1918-12-12	Sarnia	ON	Morphine	189	138
2029	Fred	Petrie	M	1923-01-25	Hamilton	ON	NULL	141	82
72	Lily	Vargas	F	1923-05-02	Hamilton	ON	Codeine	195	102
3075	Marsellus	Falcone	M	1925-03-14	Smithville	ON	Codeine	202	124
1411	Claire	Parkinson	F	1925-07-15	Dunton	ON	NULL	186	103

[실습 2] 다음 문제를 풀어주세요

- patients 테이블에서 1963년 이후 출생한 환자 중 gender가 남자(M) 인 사람을 찾으세요.
- patients 테이블에서 allergies가 NULL이 아니며, height가 170 이상인 사람을 찾으세요.
- patients 테이블에서 city가 Toronto, Ancaster, Hamilton인 환자를 생일순으로 정렬하세요.

JOIN

JOIN이 필요한 이유

- 단일 테이블로는 의료데이터 표현 불가
- 환자 / 방문 / 검사 / 처방 / 진단은 각각 다른 엔티티
- JOIN이 없으면 환자 스토리를 잇지 못함
- JOIN 누락 시 데이터 폭탄 (100만 x 100만 = 1조 row)
- 병원 EMR 기본 구조 예: Patient - Visit - LabResult

patient_id	admission_date	discharge_date	diagnosis	attending_doctor_id
1	2018-11-06	2018-11-08	Ovarian Dermoid-Cyct	21
1	2018-09-20	2018-09-20	Ineffective Breathin Pattern R/T Fluid Accumulatio	24
3	2019-01-24	2019-01-29	Cardiac Arrest	2
3	2018-10-21	2018-10-27	Congestive Heart Failure	8
6	2018-06-13	2018-06-15	Asthma Exacerbation	3

JOIN 사용 방법

- JOIN: ERD의 PK / FK 관계를 SQL에서 연결하는 것
- 하나의 SQL에서 여러 번 사용 가능



접속!! <https://www.sql-practice.com/>


INNER JOIN

```
SELECT ... FROM table_A
```

```
INNER JOIN table_B
```

```
ON A.key = B.key
```

- 두 테이블 모두 있는 행만 반환 (교집합)
- 테이블의 내용이 하나로 묶여서 나옴
- 필수 관계



INNER JOIN

```
1 SELECT * FROM admissions
2 INNER JOIN patients
3 ON admissions.patient_id = patients.patient_id;
```

patient_id	admission_date	discharge_date	diagnosis	attending_doctor_id	patient_id	first_name	last_name	gender	birth_date	city
1	2018-11-06	2018-11-08	Ovarian Dermoid-Cyct	21	1	Donald	Waterfield	M	1963-02-12	Barrie
1	2018-09-20	2018-09-20	Ineffective Breathin Pattern R/T Fluid Accumulatio	24	1	Donald	Waterfield	M	1963-02-12	Barrie
3	2019-01-24	2019-01-29	Cardiac Arrest	2	3	Jiji	Sharma	M	1957-09-05	Hamilton
3	2018-10-21	2018-10-27	Congestive Heart Failure	8	3	Jiji	Sharma	M	1957-09-05	Hamilton

[실습 1] INNER JOIN

1) 입원한 적 있는 환자의 정보만 조회를 해주세요.

힌트) patients, admissions 테이블 활용

2) 아래 조건을 만족하는 결과를 조회하세요

- 실제로 입원한 환자만
- 실제로 담당 의사가 배정된 경우만
- 환자 이름과 진단명, 의사 specialty 출력


LEFT JOIN

```
SELECT A.col1, A.col2, B.col3 FROM table_A
```

```
LEFT JOIN table_B
```

```
ON A.key = B.key
```

- 왼쪽 (A) 테이블의 모든 행은 반드시 출력
- 오른쪽 (B) 테이블에 매칭되는 값이 있으면 채우고, 없으면 NULL로 표시
- 선택적 관계



LEFT JOIN

```
1 SELECT patients.first_name, patients.last_name, province_names.province_name FROM patients
2 LEFT JOIN province_names ON province_names.province_id = patients.province_id;
```

first_name	last_name	province_name
Donald	Waterfield	Ontario
Mickey	Baasha	Ontario
Jiji	Sharma	Ontario
Blair	Diaz	Ontario
Charles	Wolfe	Ontario

[실습 2] LEFT JOIN

- 1) 모든 환자의 입원 정보를 조회하세요. 입원하지 않은 환자도 포함하여 출력하세요.
- 2) 모든 의사의 배정된 환자의 입원 정보를 조회하세요. 의사가 환자를 진료한 적이 없어도 포함하세요.

JOIN + WHERE

```
SELECT A.col1, A.col2, B.col3 FROM table_A
```

```
INNER/LEFT JOIN table_B ON A.key = B.key
```

WHERE 조건

- ON: 테이블 연결 조건
- WHERE: 연결 후 필터링 조건

=> 순서가 어긋나면 데이터 누락이 나올 수도 있음

특히 WHERE안에 JOIN 조건을 사용하면 데이터가 잘리는 경우가 많음

[실습 3] JOIN + WHERE

- 1) patient 테이블을 기준으로 LEFT JOIN을 사용하여 모든 환자들의 정보 + 지역명을 가져오고
그 중에서 province_id = 'AB'인 환자만 조회하세요.
- 2) patients와 admissions를 INNER JOIN하여 입원 기록이 있는 환자만 대상이 되도록 하고,
그 중에서 진단명이 'Cancer'인 경우만 남기세요.

(추가) ALIAS 별칭 / DISTINCT

- Alias: 별칭 -> 짧게 쓰기 가능

SELECT column명 AS 별칭 FROM table_name ;	# Column 별칭
SELECT ... FROM table_name AS 별칭 ;	# Table 별칭

- DISTINCT: 중복 제거

```
SELECT DISTINCT column명 FROM table_name;
```

**GROUP BY / HAVING /
LIMIT / Aggregation**

GROUP BY

```
SELECT * FROM table_A  
GROUP BY group_column;
```

- “데이터를 묶는 기준”
- 예) 성별 / 도시 / 의사별 / 날짜별 등
- GROUP BY는 SELECT 안에 있는 비집계 Column과 일치해야 함

```
1 SELECT * FROM admissions  
2 GROUP BY patient_id;
```

patient_id	admission_date	discharge_date	diagnosis	attending_doctor_id
1	2018-09-20	2018-09-20	Ineffective Breathin Pattern R/T Fluid Accumulatio	24
3	2018-10-21	2018-10-27	Congestive Heart Failure	8
6	2018-06-13	2018-06-15	Asthma Exacerbation	3
7	2018-06-24	2018-07-03	Cancer	8
8	2018-09-18	2018-09-21	Amigima	6

HAVING

```
SELECT * FROM table_A
GROUP BY group_column
HAVING 조건;
```

- GROUP BY 이후 사용 가능 => 그 외 것들과 조합해서 사용 불가
- GROUP BY 결과를 다시 필터링

```
1 SELECT * FROM admissions
2 GROUP BY patient_id
3 HAVING patient_id % 2 == 1;
```

patient_id	admission_date	discharge_date	diagnosis	attending_doctor_id
1	2018-09-20	2018-09-20	Ineffective Breathin Pattern R/T Fluid Accumulatio	24
3	2018-10-21	2018-10-27	Congestive Heart Failure	8
7	2018-06-24	2018-07-03	Cancer	8
9	2018-12-31	2018-12-31	Ruptured Appendicitis	19

LIMIT

```
SELECT * FROM table_A  
LIMIT 개수; 또는 LIMIT offset, 개수;
```

- 결과 개수 제한
- 긴 테이블을 조회할 때 필수
 - 실무에서 대형테이블에 SELECT *는 위험
- 조회 속도를 빠르게 할 때 사용: pagination에서 사용

LIMIT

```
1 SELECT * FROM patients
2 LIMIT 3;
```

patient_id	first_name	last_name	gender	birth_date	city	province_id	allergies	height	weight
1	Donald	Waterfield	M	1963-02-12	Barrie	ON	NULL	156	65
2	Mickey	Baasha	M	1981-05-28	Dundas	ON	Sulfa	185	76
3	Jiji	Sharma	M	1957-09-05	Hamilton	ON	Penicillin	194	106

```
1 SELECT * FROM patients
2 LIMIT 10, 3;
```

patient_id	first_name	last_name	gender	birth_date	city	province_id	allergies	height	weight
11	Hank	Spencer	M	1969-08-10	Peterborough	ON	NULL	158	74
12	Sara	di Marco	F	1949-04-29	Hamilton	ON	NULL	145	46
13	Daphne	Seabright	F	1954-11-18	Ancaster	ON	Codeine	146	77

[실습 4] GROUP BY + HAVING / LIMIT

- 1) 환자를 지역(province_id)별로 그룹화하고, 그 지역 코드가 'NL'인 그룹만 조회하세요. [WHERE 사용 금지]
- 2) 의사 중 doctor_id가 offset이 10인 곳부터 10개의 행을 반환하세요.
[WHERE 사용 금지]

QnA